


Projet final de Deep Learning

Encadré par Maxime Devanne

Rapport sur la Classification des Signaux ECG à l'aide de réseaux de neurones



1. Introduction

Les maladies cardiovasculaires demeurent un défi majeur de santé publique, représentant l'une des principales causes de décès à l'échelle mondiale. Face à cette réalité, la nécessité de détecter précocement les anomalies cardiaques revêt une importance cruciale dans la gestion médicale. Les signaux électrocardiographiques (ECG), en tant que reflet graphique de l'activité électrique du cœur, offrent une fenêtre précieuse pour comprendre les états physiologiques et identifier toute perturbation.

Ce projet se situe au cœur de la problématique cruciale de la détection précoce des anomalies cardiaques en explorant l'utilisation conjointe de deux architectures de réseaux de neurones : les réseaux de neurones récurrents (RNN) et les réseaux de neurones convolutifs (CNN). Les RNN, reconnus pour leur aptitude à capturer les dépendances séquentielles dans les données, et les CNN, spécialisés dans l'extraction de caractéristiques spatiales, se complètent pour une analyse robuste des séquences temporelles telles que les signaux électrocardiographiques (ECG). L'objectif essentiel de ce projet est de mettre au point une méthode automatisée, intégrant ces deux architectures, afin de détecter de manière efficiente et fiable les anomalies cardiaques. Cette approche novatrice s'inscrit dans une perspective d'intégration harmonieuse dans les processus de diagnostic médical, renforçant ainsi les capacités des professionnels de la santé dans la gestion des maladies cardiovasculaires.

2. Objectifs

L'objectif principal de ce projet est d'entreprendre une étude approfondie, le développement et l'évaluation de modèles de réseaux de neurones récurrents (RNN) dans le but de différencier les signaux électrocardiographiques (ECG) normaux de ceux présentant des anomalies cardiaques. Cette entreprise repose sur l'utilisation du jeu de données ECG200, une compilation de signaux ECG préalablement normalisés à des fins de classification.

Les sous-objectifs de ce projet sont les suivants :

Étude approfondie : Examiner les caractéristiques des signaux ECG, les types d'anomalies cardiaques présentes dans le jeu de données, et les défis spécifiques liés à la classification automatique de ces signaux.

Développement de modèles RNN : Concevoir et mettre en œuvre des architectures de réseaux de neurones récurrents adaptées à la nature séquentielle des signaux ECG. Cela implique l'exploration de différentes tailles de couches LSTM, l'ajout de couches Dropout pour la régularisation, et l'intégration d'une couche Dense supplémentaire pour la sortie.

Évaluation des performances : Évaluer les modèles développés en utilisant le jeu de données ECG200. Ceci comprend la séparation du jeu de données en ensembles d'entraînement, de validation et de test, ainsi que l'optimisation des hyperparamètres pour garantir des performances optimales.

Comparaison des modèles : Analyser les performances des modèles RNN en les comparant à d'autres architectures potentielles, telles que les modèles Convolutional Neural Networks (CNN) ou d'autres approches classiques de traitement du signal pour la classification ECG.

Interprétation des résultats : Comprendre les implications cliniques des résultats obtenus en termes de précision, de rappel et de F1-score, en mettant en lumière la capacité des modèles à détecter efficacement les signaux ECG anormaux tout en minimisant les faux positifs et les faux négatifs.

À travers ces objectifs, ce projet aspire à contribuer de manière significative à l'avancement des techniques de détection précoce des anomalies cardiaques, en exploitant les capacités des réseaux de neurones récurrents dans le domaine spécifique de la classification des signaux ECG.

3. Méthodologie

3.1 Prétraitement des Données

Les signaux ECG du jeu de données ECG200 ont été prétraités, normalisés et répartis en ensembles d'entraînement, de validation et de test.

3.2 Architecture des réseaux de neurones

Nous avons expérimenté deux architectures de réseaux de neurones :

Modèle CNN :

Le modèle de réseau de neurones convolutionnels (CNN) adopté pour la classification des signaux électrocardiographiques (ECG) présente une architecture stratégiquement conçue pour extraire des caractéristiques temporelles importantes. Voici une décomposition détaillée de cette architecture :

Entrée (Input) :

- Les données d'entrée sont représentées par des séquences temporelles de signaux ECG.
- La forme de l'entrée est déterminée par `input_shape`, dérivée des données d'entraînement : (nombre_de_points_temporels, 1).

Couches Convolutives 1D (Conv1D) :

- Première couche convolutive avec 10 filtres et des fenêtres (kernels) de taille 5.
- Activation ReLU pour introduire la non-linéarité dans les caractéristiques extraites.
- Suivie d'une couche de max pooling 1D pour réduire la dimensionnalité et préserver les informations essentielles.
- Deuxième couche convolutive avec 20 filtres et des fenêtres de taille 5.
- Activation ReLU pour capturer des caractéristiques plus complexes.
- Nouvelle couche de max pooling 1D pour réduire davantage la dimensionnalité.

Couche Flatten :

- Aplatissement de la sortie des couches de pooling en un vecteur unidimensionnel, préparant les données pour les couches entièrement connectées.

Couche Dense (Fully Connected) :

- Couche dense avec 100 unités et activation ReLU.
- Cette couche entièrement connectée fusionne les caractéristiques extraites par les couches convolutionnelles.

Couche de Sortie (Output) :

- Couche dense de sortie avec un nombre d'unités égal au nombre de classes (2 pour la classification binaire).
- Activation softmax pour générer des probabilités de chaque classe.

Compilation du Modèle :

- Utilisation de la fonction de perte `sparse_categorical_crossentropy` pour la classification.
- Optimiseur SGD avec un taux d'apprentissage de 0.1.
- Métrique d'évaluation : exactitude (accuracy).

Chargement du Modèle Sauvegardé :

- Chargement du modèle sauvegardé ('best-model.h5') pour l'évaluation finale et la génération du rapport de classification.

Cette architecture cherche à capturer des motifs temporels significatifs dans les signaux ECG, fournissant ainsi une base solide pour la classification précise des anomalies cardiaques. Les résultats finaux, accompagnés des métriques de performance, seront détaillés dans la section d'analyse des résultats du rapport.

Modèle RNN :

Architecture générale du Modèle RNN :

Architecture avec deux couches LSTM ainsi que du dropout et une fonction d'activation sigmoïde.

L'ajout d'une deuxième couche LSTM avec une taille de neurones réduite vise à capturer des motifs plus complexes ou spécifiques dans les signaux ECG, tout en évitant une complexité excessive qui pourrait conduire à un surajustement du modèle.

Les couches Dropout sont utilisées pour éviter le surapprentissage en désactivant aléatoirement certains neurones pendant l'entraînement, forçant le modèle à généraliser davantage.

La fonction d'activation sigmoïde est utilisée dans la couche de sortie pour produire une probabilité, où les valeurs prédites sont interprétées comme la probabilité d'un signal ECG présentant une anomalie cardiaque.

Architecture détaillée du Modèle RNN :

Couche LSTM (64 neurones) avec retour de séquence :

Cette couche LSTM initiale est configurée pour renvoyer les séquences complètes. Elle prend en entrée les signaux ECG sous forme de séquences et les traite en parallèle, capturant les informations temporelles importantes.

Couche Dropout (0.2) :

Une couche de dropout est ajoutée pour régulariser le modèle et réduire le surajustement potentiel en désactivant aléatoirement un pourcentage des neurones lors de l'entraînement.

Couche LSTM (32 neurones) :

Une deuxième couche LSTM est introduite après la couche de dropout. Cette couche permet de capturer des représentations plus abstraites ou des informations plus fines des signaux ECG en utilisant une dimensionnalité réduite.

Couche Dropout (0.2) :

Une autre couche de dropout est appliquée après la deuxième couche LSTM pour poursuivre la régularisation du modèle et éviter le surapprentissage.

Couche Dense de sortie (1 neurone, fonction d'activation sigmoïde) :

Enfin, une couche de sortie dense est utilisée pour obtenir la prédiction binaire finale, indiquant la classification du signal ECG comme normal ou présentant une anomalie cardiaque.

3.3 Entraînement et Évaluation

Entraînement :

Les modèles ont été soigneusement entraînés sur l'ensemble d'entraînement en utilisant une approche de validation croisée. La validation croisée est une stratégie qui implique de diviser l'ensemble d'entraînement en plusieurs sous-ensembles, permettant ainsi une évaluation robuste des performances du modèle sur différentes partitions des données.

Pour le CNN, l'entraînement a été réalisé sur 100 epochs avec un mini-batch size de 256. Un processus de validation a été intégré en dédiant 30% de l'ensemble d'entraînement à la validation. Cette configuration a permis d'optimiser la généralisation du modèle en évitant le surajustement aux données d'entraînement.

Pour le RNN, l'entraînement a été réalisé sur 100 epochs avec un mini-batch size de 256. Un processus de validation a été intégré en dédiant 30% de l'ensemble d'entraînement à la validation.

Les hyperparamètres, tels que le taux d'apprentissage et les paramètres spécifiques aux couches, ont été finement réglés pour maximiser les performances du modèle. Cette étape a été cruciale pour garantir une convergence efficace lors de l'entraînement et une capacité du modèle à capturer des motifs pertinents dans les signaux ECG.

Évaluation :

L'évaluation des modèles a été effectuée de manière exhaustive sur plusieurs aspects :

Précision, Rappel et F1-score : Les modèles ont été évalués en utilisant des métriques clés telles que la précision, le rappel et le F1-score. Ces métriques fournissent une compréhension détaillée de la capacité du modèle à classifier correctement les signaux ECG normaux et anormaux.

Matrice de Confusion : Une matrice de confusion a été générée pour visualiser les performances du modèle en termes de vrais positifs, faux positifs, vrais négatifs et faux négatifs. Cette visualisation offre un aperçu détaillé des erreurs de classification.

Graphiques d'Apprentissage : Des graphiques ont été créés pour suivre l'apprentissage du modèle au fil des epochs. Les courbes de perte et d'exactitude sur l'ensemble d'entraînement et de validation permettent de détecter d'éventuels signes de surajustement ou de sous-ajustement.

Analyse des Résultats : Une analyse approfondie des résultats a été réalisée en comparant les métriques d'évaluation sur l'ensemble de test. Cette analyse inclut une interprétation des performances en termes de sensibilité, spécificité et capacité du modèle à gérer les deux classes.

L'ensemble de ces éléments d'évaluation a été intégré pour fournir une évaluation complète des modèles, permettant ainsi une compréhension approfondie de leur capacité à détecter les anomalies cardiaques dans les signaux ECG. Les résultats détaillés sont présentés dans la section suivante du rapport.

4. Résultats

Les modèles ont été évalués sur l'ensemble de test pour mesurer leurs performances en termes de précision, de rappel, de F1-score et de matrice de confusion.

Modèle CNN :

Précision :



- Pour la classe 0: **78%** des exemples prédits comme appartenant à la classe 0 étaient corrects, et **22%** étaient des faux positifs.
- Pour la classe 1: **89%** des exemples prédits comme appartenant à la classe 1 étaient corrects, et **11%** étaient des faux positifs.
- En moyenne, la précision est de **84%**, et par pondération, elle est de **85%**.

Rappel :


- Pour la classe 0: **81%** des exemples réels de la classe 0 ont été correctement prédits, et **19%** étaient des faux négatifs.
- Pour la classe 1: **88%** des exemples réels de la classe 1 ont été correctement prédits, et **12%** étaient des faux négatifs.
- En moyenne, le rappel est de **84%**.

F1-score :

- Pour la classe 0 : L'harmonique moyenne de la précision et du rappel est de **79%**.
- Pour la classe 1 : L'harmonique moyenne de la précision et du rappel est de **88%**.
- En moyenne, le F1-score est de **84%**.



Matrice de Confusion :



Modèle RNN:

Précision :


- Pour la classe 0: **67%** des exemples prédits comme appartenant à la classe 0 étaient corrects, et **33%** étaient des faux positifs.
- Pour la classe 1: **84%** des exemples prédits comme appartenant à la classe 1 étaient corrects, et **16%** étaient des faux positifs.
- En moyenne, la précision est de **75%**, et par pondération, elle est de **78%**.

Rappel :


- Pour la classe 0: **72%** des exemples réels de la classe 0 ont été correctement prédits, et **28%** étaient des faux négatifs.
- Pour la classe 1: **80%** des exemples réels de la classe 1 ont été correctement prédits, et **20%** étaient des faux négatifs.
- En moyenne, le rappel est de **76%**.

F1-score :

- Pour la classe 0 : L'harmonique moyenne de la précision et du rappel est de **69**.
- Pour la classe 1 : L'harmonique moyenne de la précision et du rappel est de **82**.
- En moyenne, le F1-score est de **76%**.



Matrice de Confusion :



5. Analyse des Résultats

Les performances des modèles ont été analysées en comparant les métriques d'évaluation. Nous avons observé que le modèle CNN a démontré une précision de 84%, un rappel de 84%, et un F1-score de 84%. Ces résultats indiquent que le modèle CNN présente une capacité significative à distinguer les signaux ECG normaux des signaux présentant des anomalies cardiaques.

D'un autre côté, le modèle RNN a également été évalué avec une précision de 73%, un rappel de 75%, et un F1-score de 74%. Ces résultats suggèrent que le modèle RNN a également des performances encourageantes dans la classification des signaux ECG.

En comparant les deux modèles, nous pouvons tirer des conclusions intéressantes sur leur efficacité respective. Le modèle CNN semble exceller en termes de précision alors que le modèle RNN montre des performances inférieures dans notre cas. Le modèle du RNN peut sûrement encore être amélioré sur ce problème pour nous permettre d'obtenir des résultats plus encourageants. Avec les modèles que nous avons utilisés, le CNN semble être plus efficace que le RNN sur ce problème de classification des signaux ECG.

6. Conclusion

Ce projet a exploré l'utilisation de modèles de réseaux de neurones pour la classification des signaux ECG, en mettant particulièrement l'accent sur les modèles CNN et RNN. Les résultats obtenus montrent que les deux architectures de réseaux de neurones sont capables de fournir des performances prometteuses dans la détection des anomalies cardiaques à partir de signaux ECG.

Il est essentiel de souligner que le choix entre le modèle CNN et le modèle RNN dépendra des exigences spécifiques du contexte d'application. Si une précision élevée est la priorité absolue, le modèle CNN peut être préféré. Cependant, si un équilibre entre la précision et le rappel est recherché, le modèle RNN peut être plus adapté.

Ce projet sert de base pour des développements futurs, notamment l'exploration d'autres architectures de réseaux de neurones, l'augmentation de la taille du jeu de données, et l'optimisation continue des hyperparamètres pour améliorer davantage les performances des modèles de classification des signaux ECG. En conclusion, les avancées dans ce domaine pourraient contribuer de manière significative à la détection précoce des maladies cardiovasculaires et à l'amélioration des soins médicaux.

7. Sources

- Train Dataset : https://maxime-devanne.com/datasets/ECG200/ECG200_TRAIN.tsv
- Test Dataset : https://maxime-devanne.com/datasets/ECG200/ECG200_TEST.tsv

- Code source CNN :
https://colab.research.google.com/drive/1jNDjSzDsXRKWVINMMzsFbLrVCOB_GAp
- Code source RNN :
https://colab.research.google.com/drive/1bY92pVih6GI8qIFgA0d_ObshjDO5HFGr?usp=sharing